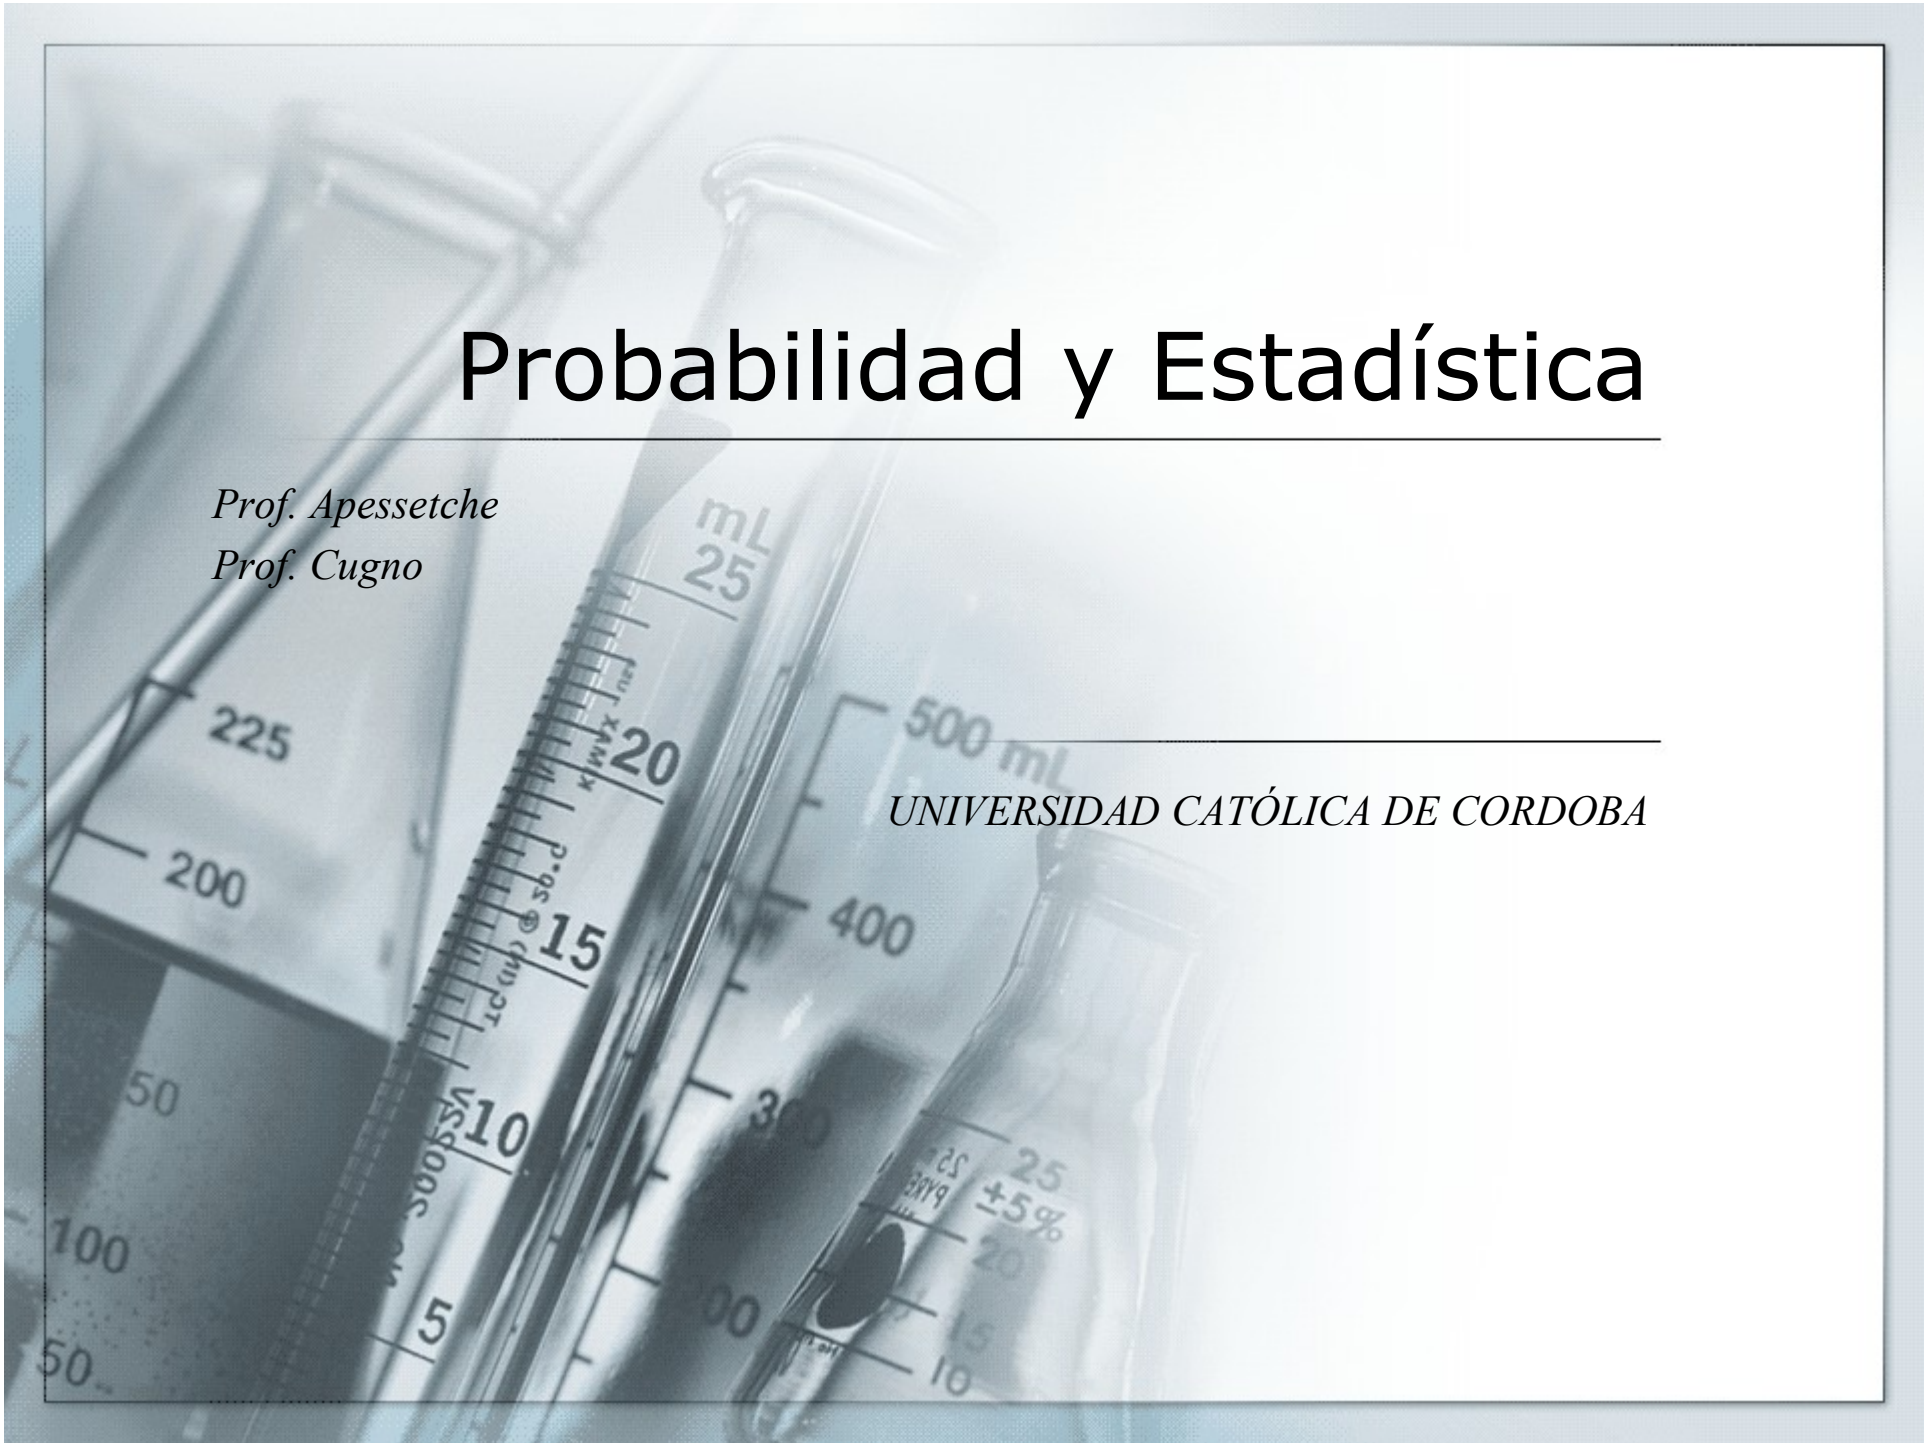


# Probabilidad y Estadística

*Prof. Apessetche*
*Prof. Cugno*

*UNIVERSIDAD CATÓLICA DE CORDOBA*

# ¿Qué es la Estadística?

- La estadística esta constituida por el conjunto de técnicas y métodos que permiten estudiar y determinar de una muestra debidamente representativa de una población, los valores estadísticos a fin de poder inferir sobre los parámetros poblacionales con un cierto grado de bondad
- Existen dos tipos de estadistica, descriptiva e inferential

# Análisis de datos

## Análisis Descriptivo

*Analiza e interpreta lo que ha sucedido.*

- → Qué pasó
- → Cómo pasó



## Análisis Predictivo

*A partir de lo sucedido intenta predecir lo que sucederá.*

- → Por qué pasó
- → Qué podría pasar



## Análisis Prescriptivo

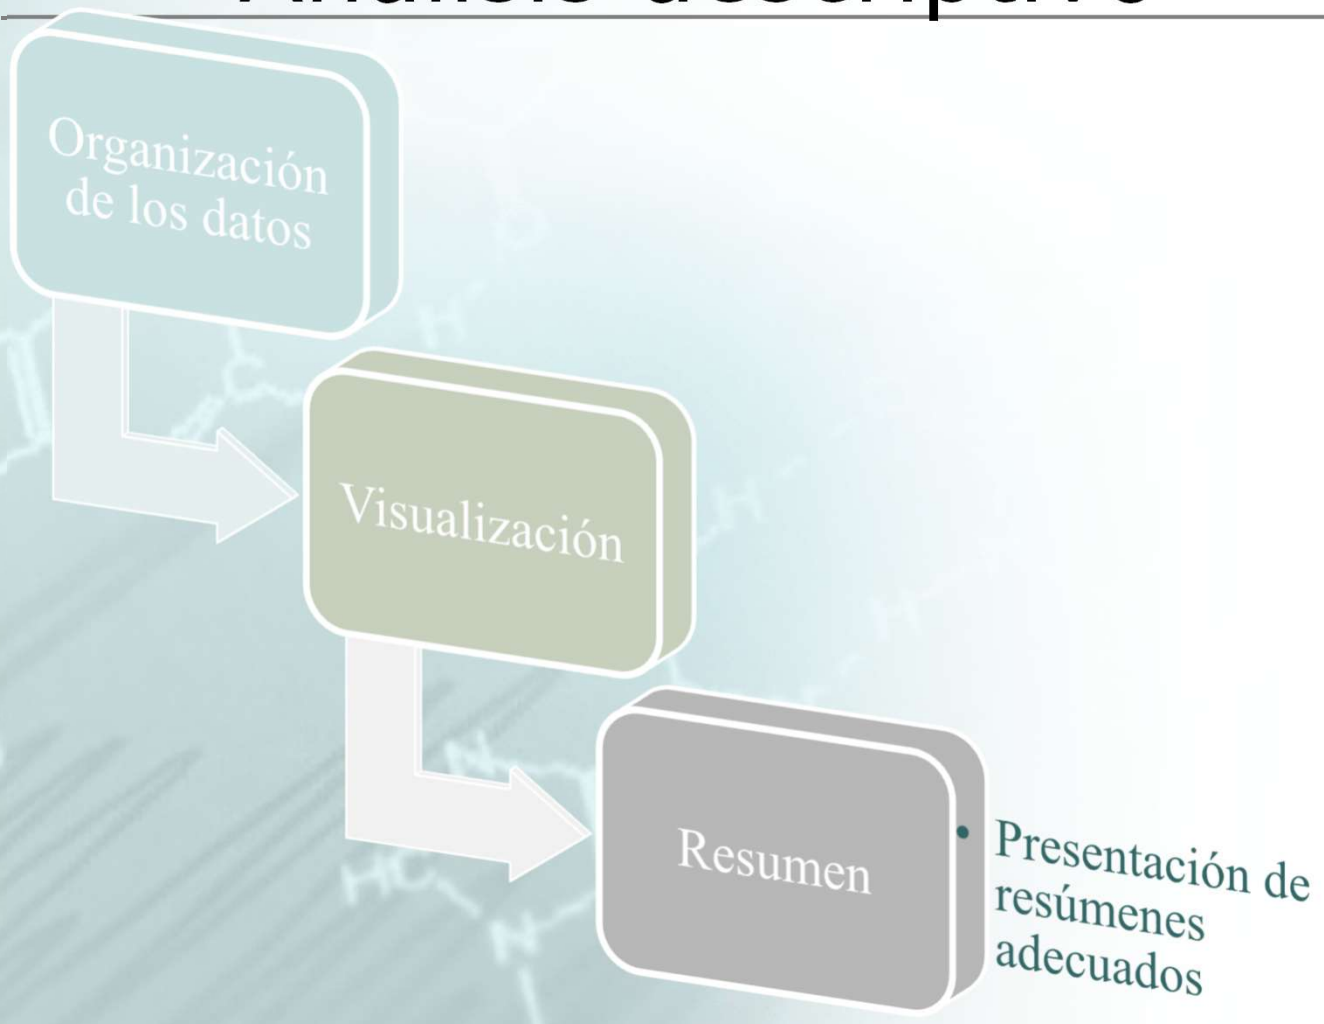
*Identifica estrategias y acciones que mejoren los resultados previstos.*

- → Qué hacer
- → Cómo hacerlo



Fuente: El Arte de Medir

# Análisis descriptivo



# Conceptos principales

- Población
- Variables
- Muestra
- Unidad de análisis

# Población,variable, muestra y unidad de análisis

- Población: Conjunto de elementos que tienen la "característica" que se desea estudiar. Esta esta acotada en espacio y tiempo

- Variables: son las caracteristicas que se desean estudiar

- Unidad de análisis: es el elemento sobre el cual se van a extraer los datos
- Muestra: es un subconjunto(representativo) de la Población

# Población,variable, muestra y unidad de análisis

**a.** Se realizó una encuesta entre 345 estudiantes universitarios para averiguar quién sale a correr en el tiempo libre.

Población:

Muestra:

Variable:

**b.** Una fábrica de bicicletas realizó una encuesta entre 547 alumnos de preescolar para saber cuántos chicos andan en bicicleta sin rueditas.

Población:

Muestra:

Variable:

**c.** Una empresa de telefonía realizó un estudio de mercado para averiguar la cantidad de tiempo que hablan 12 453 de sus abonados.

Población:

Muestra:

Variable:

**d.** Una empresa de turismo realizó una encuesta a 100 familias para saber cuál es el destino elegido para viajar en las próximas vacaciones.

Población:

Muestra:

Variable:

# Muestra debidamente representativa

- Una muestra debidamente representativa debe representar las mismas características de la población. Para ellos la muestra debe ser extraída al azar(MAS, estratificado, conglomerado y sistemático)

Ejemplos

Para saber la audiencia de un programa de tv se interroga al azar 1000 abonados telefónicos

Para conocer el numero de viviendas de la ciudad de Córdoba que tienen cloacas se eligen 500 viviendas de Alta Córdoba

# Parámetro, estimador y Estadístico

- Los valores en estudio, que en la muestra toman el nombre de ESTADISTICOS en la población se los denomina PARÁMETROS
- **Parámetro**: Característica poblacional,como por el ejemplo la media
- **Estimador**: característica que proviene de la muestra, por ejemplo la media
- **Estadístico**: es una relación matemática entre el parámetro y su estimador con el fin de inferir

Estimador $\longrightarrow$ Muestra

Parámetro $\longrightarrow$ Población

# Variable y tipos de variables

- Variable: es una característica o atributo de interés sobre el cual los elementos de una población difieren. Se denota con X, Y, Z, etc.
- Categorías: son todos los valores que asume la variable.
- Dato: Es cada realización de las categorías de la variable

Ejemplos

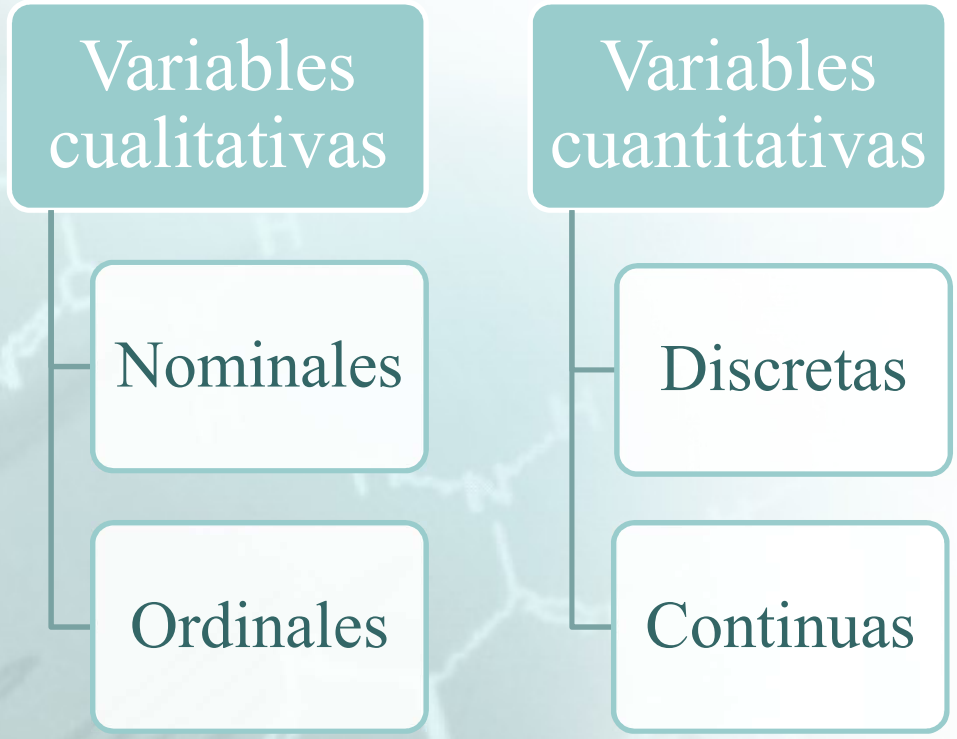
X: género, con categorías V o M.

Y: Nivel de escolaridad con categorías primario, sec., universitario.

Z: Peso de los adulto con categorías en [50kg; 150kg]

W: Cantidad de TV por hogar, con categorías 0, 1, 2, etc.

# Clasificación de las variables



# Clasificación de las variables

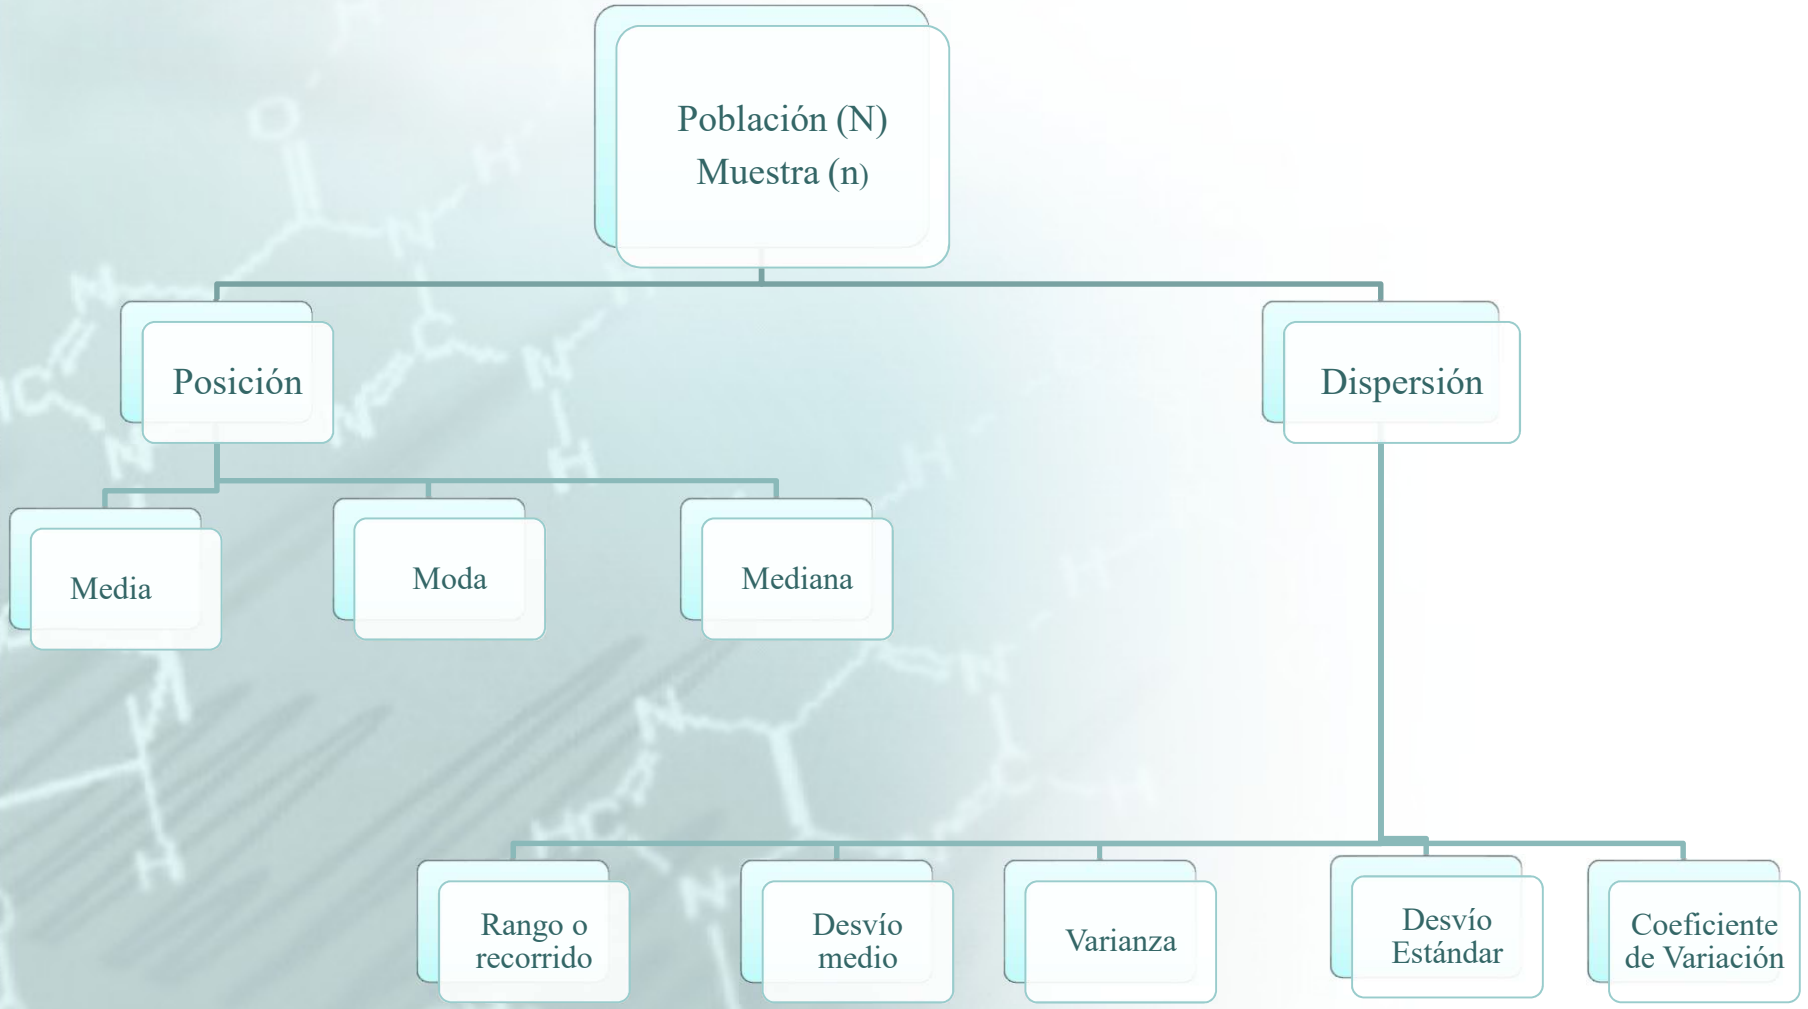
- Nominales: Cuando las categorías son nominas, no respetan un orden jerárquico
- Ordinales: Están constituidos por los valores relativos asignados por denotar cierto orden. Cuando las categorías respetan un orden jerárquico
- Discretas: sus categorías representan de un conteo.
- Continuas: Cuando sus categorías representan una medición

# Actividad 1

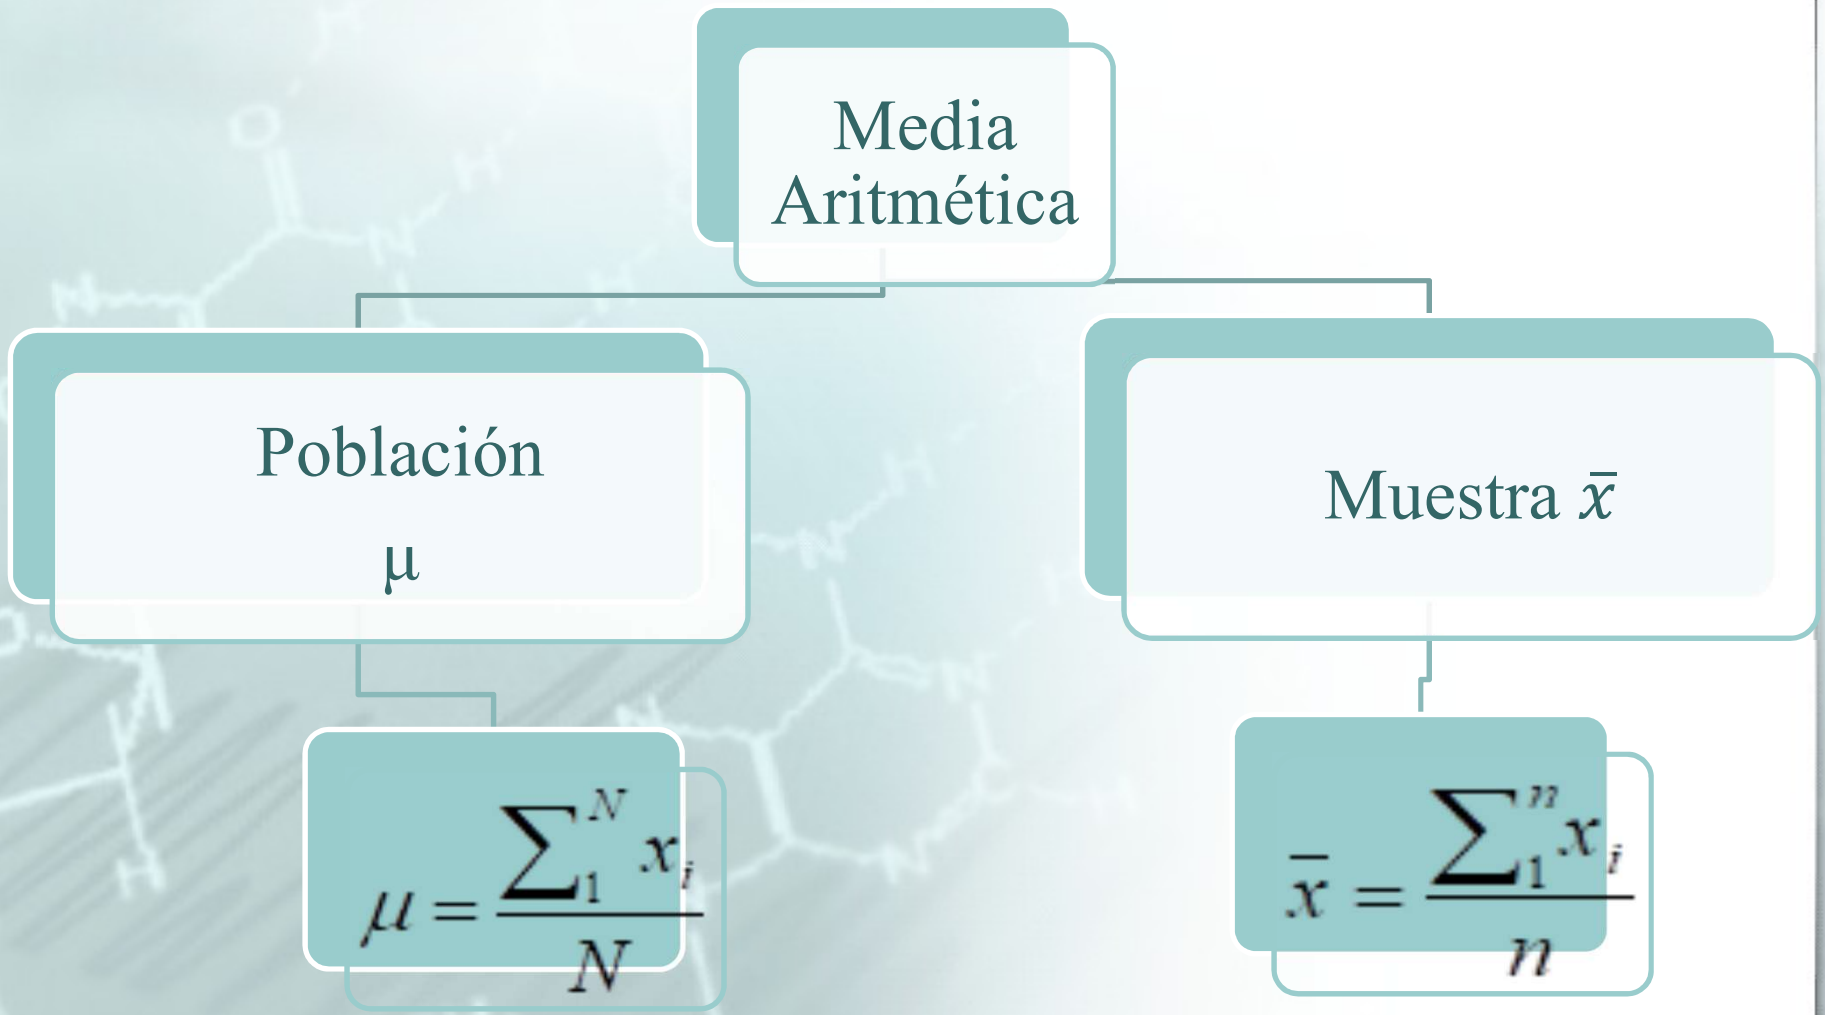
1. Clasificar las variables de acuerdo a su categoría

| Variable | Categoría |
|---|---|
| Cantidad de alumnos con celular por curso | 0,1,2,3….. |
| Genero de alumnos | Femenino, masculino |
| Equipo de futbol favorito | Boca, River, Belgrano… |
| Desempeño en el trabajo | Malo, bueno, regular, muy bueno, excelente. |
| Numero de accidentes automovilísticos anuales en un ciudad | 0,1,2,3 |
| Peso de los alumnos | [35kg, 100kg] |

# Parámetros y estadísticos



# Medidas de Posición



# Media Aritmética

Media aritmética

$$\bar{X} = \frac{\sum_{i=1}^{n} x_i}{n}$$

- Todo conjunto de escala medible tiene una media
- Un conjunto de datos tiene solo una media
- En su calculo, se incluyen todos los valores de la variable, por lo cual es sendible a los valores extremos y puede no ser representativa

# El engañoso promedio

- Félix fue a buscar trabajo a una empresa poderosa.
- La dirección de la empresa está a cargo del Sr. Artilugio, su hermano y seis parientes. La fuerza laboral la forman 10 operarios.
- La empresa va muy bien, y se necesita un operario más.
- El Sr. Artilugio durante la entrevista comenta a Félix, que el sueldo promedio de la empresa es $600000. Félix comienza a trabajar

# El engañoso promedio

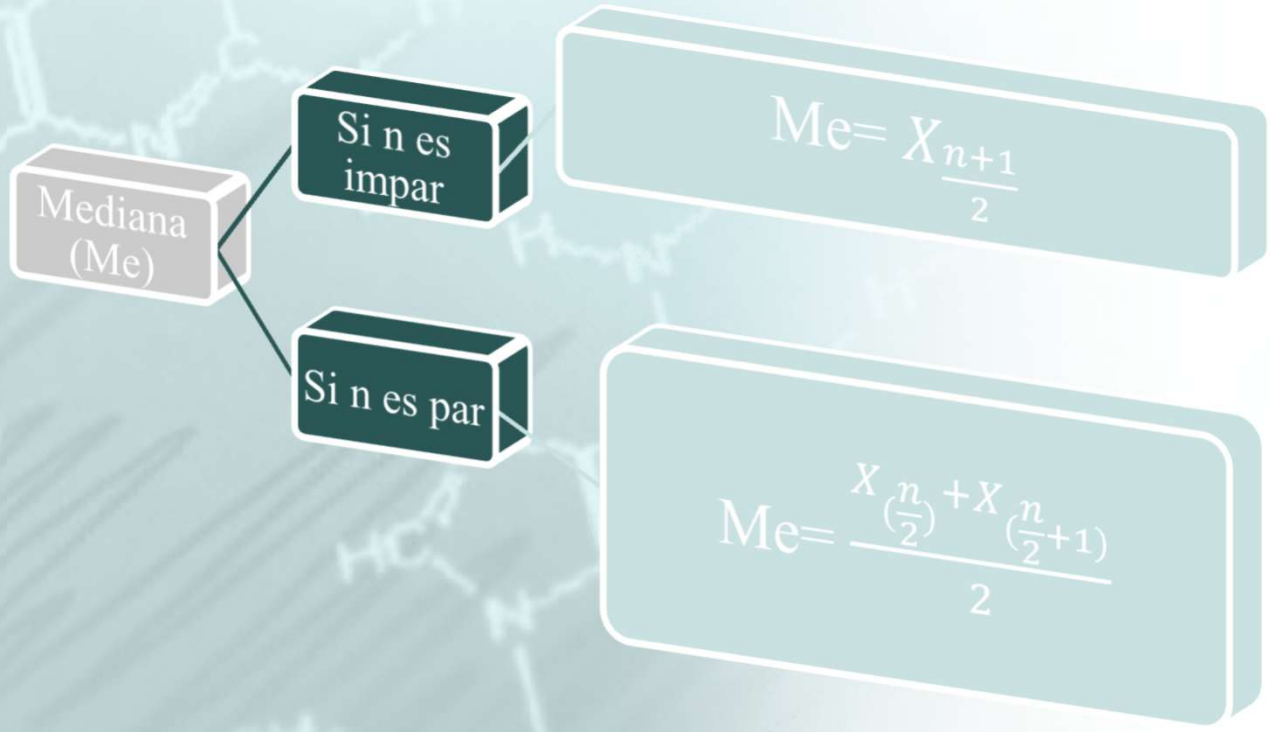
- Al cabo de un mes de trabajo, Félix muy molesto se dirige al Sr Artilugio y le reclama: ¡ Ud. Me ha engañado, ninguno de los operarios gana mas de $200000.

  * El Sr. Artilugio le demuestra que no lo ha engañado:

| | | |
|---|---|---|
| * Yo gano…… | | $4800000 |
| * Mi hermano…… | | $2000000 |
| * Parientes | 6 x $500000 | $3000000 |
| * Capataces | 5 x $400000 | $2000000 |
| * Operarios | 10 x $200000 | $2000000 |
| * Total: | | $13800000 |

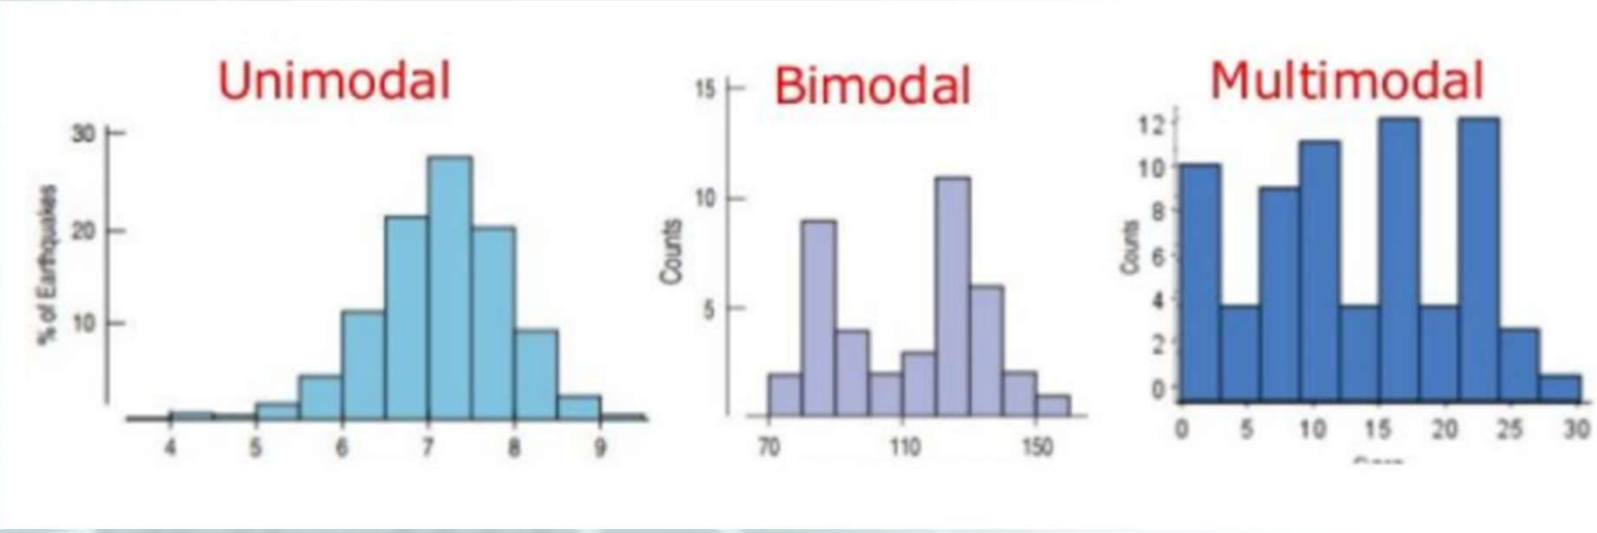
# Mediana

- Se define como mediana de una distribución al valor de la misma que ocupa el punto medio
- Se puede calcular para escalas de medicion al menos ordinales
- No es sensibles a valores extremos, por lo que es una medida robusta



# Moda

Se define como moda de una distribución al valor que mas veces se repite.



# Cuartiles

Son medidas descriptivas que dividen los datos ordenados en cuartos.

El Primer Cuartil ($Q_1$) es un valor de la variable que divide el 25 % de los valores más bajos del 75 % de los valores restantes.

Me

El Tercer Cuartil ($Q_3$) es un valor de la variable que divide el 25 % de los valores más altos del 75 % de los valores restantes.

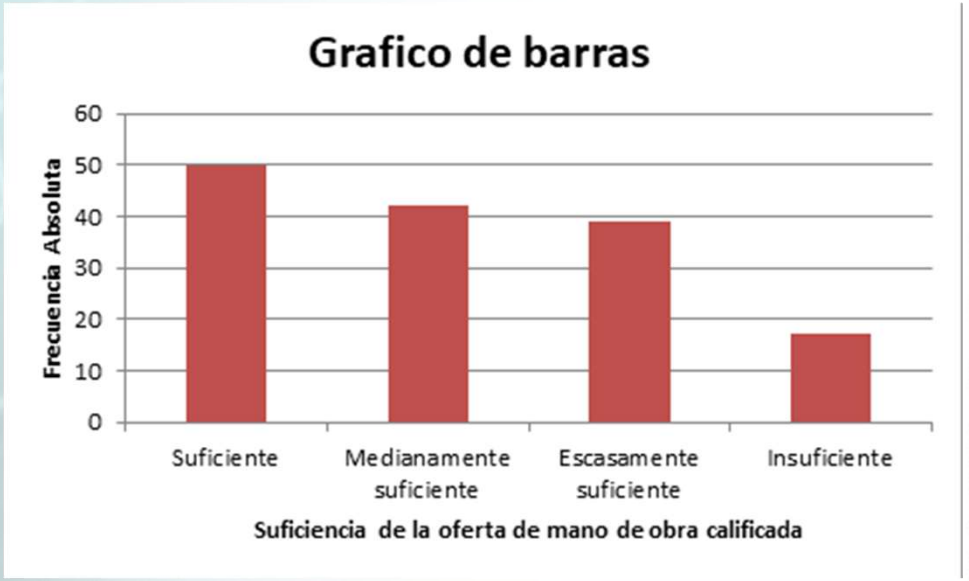


# Organización y presentación de los datos

- Distribuciones unidimensionales (Variable categórica)

- **Tabla 1: Suficiencia de la oferta de mano de obra calificada**

| Suficiencia de la oferta de mano de obra calificada | Frecuencia absoluta | Porcentaje |
|---|---|---|
| Suficiente | 50 | 33.8 |
| Medianamente suficiente | 42 | 28.4 |
| Escasamente suficiente | 39 | 26.4 |
| Insuficiente | 17 | 11.5 |
| Total | 148 | 100 |



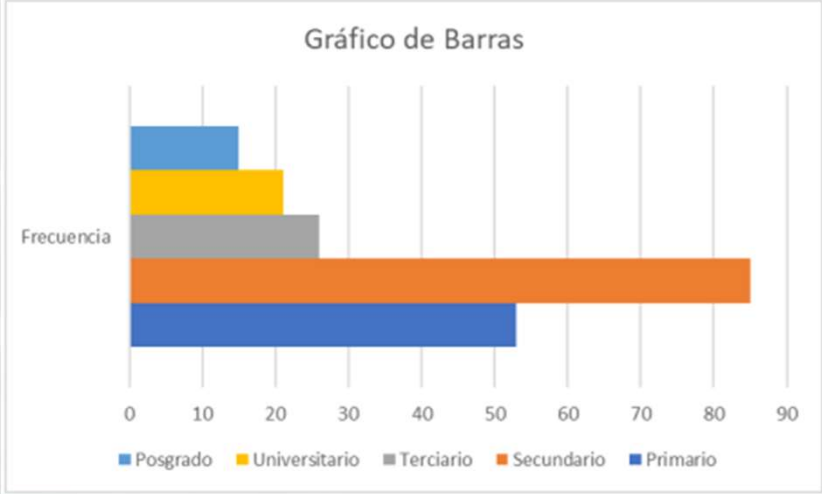
# Organización y presentación de los datos

| Nivel Educativo | Frecuencia | Frecuencia Relativa | % |
|---|---|---|---|
| Primario | 53 | 0,265 | 26,5% |
| Secundario | 85 | 0,425 | 42,5% |
| Terciario | 26 | 0,13 | 13,0% |
| Universitario | 21 | 0,105 | 10,5% |
| Posgrado | 15 | 0,075 | 7,5% |







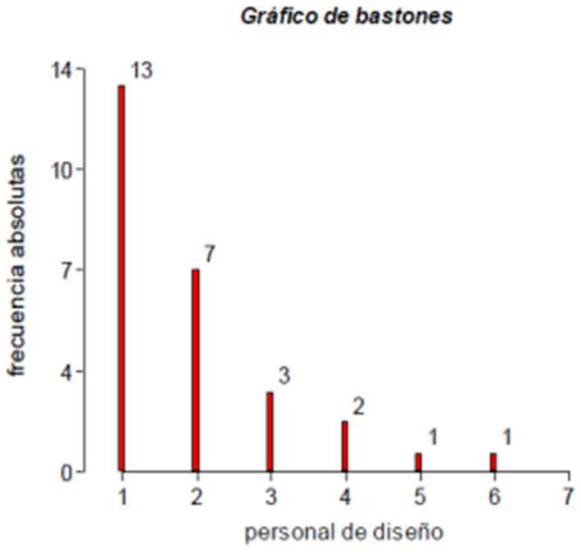


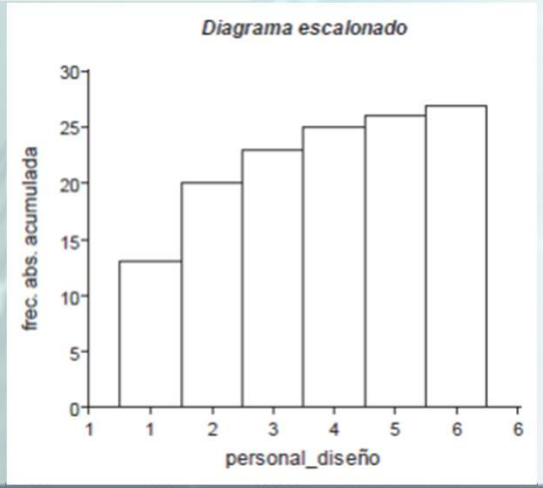
# Organización y presentación de los datos

- Distribuciones unidimensionales (Variable numerica discreta)

**Tabla 1.3.** Cantidad de empleados área Diseño e Ingeniería Industrial

| EMPLEADOS QUE REALIZAN LA ACTIVIDAD $X_i$ | FRECUENCIA ($n_i$) | FRECUENCIA RELATIVA ($h_i$) | FRECUENCIA ABSOLUTA ACUM. ($N_i$) | FRECUENCIA RELATIVA ACUM. ($H_i$) |
|---|---|---|---|---|
| 1 | 13 | 0.46 | 13 | 0.46 |
| 2 | 7 | 0.25 | 20 | 0.71 |
| 3 | 3 | 0.11 | 23 | 0.82 |
| 4 | 2 | 0.07 | 25 | 0.89 |
| 5 | 2 | 0.07 | 27 | 0.96 |
| 6 | 1 | 0.04 | 28 | 1.00 |
| **Total** | **28** | **1.00** | | |



# Ejercitación

**1.** En el proceso de control final de tanques de combustible para automóviles, se realiza una prueba para verificar la estanqueidad del recipiente. Suponga que estas observaciones se organizan del siguiente modo: se observan cien tanques consecutivos y se registra la cantidad de depósitos que pierden; luego se observan otras cien unidades y nuevamente se registra el número de tanques con pérdidas. De este modo, se inspeccionan sesenta muestras aleatorias y se obtienen los siguientes valores.

| | | | | | | | | | |
|---|---|---|---|---|---|---|---|---|---|
| 4 | 2 | 1 | 7 | 2 | 0 | 5 | 4 | 3 | 5 |
| 2 | 4 | 4 | 1 | 1 | 2 | 4 | 1 | 5 | 4 |
| 3 | 2 | 3 | 4 | 4 | 6 | 5 | 5 | 2 | 2 |
| 3 | 4 | 4 | 4 | 2 | 6 | 2 | 5 | 6 | 4 |
| 1 | 2 | 0 | 4 | 5 | 3 | 1 | 3 | 5 | 4 |
| 2 | 3 | 3 | 5 | 5 | 9 | 4 | 5 | 4 | 3 |

**a.** Analizar qué tipos de datos son estos.

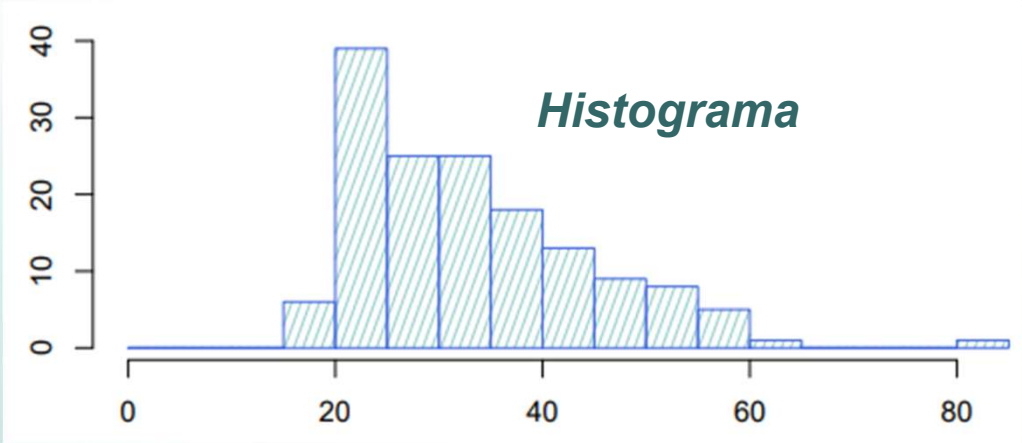
**b.** Construir una Tabla de Frecuencias y elaborar un gráfico adecuado que permita visualizar esta información.

**c.** Calcular las principales medidas que resuman toda la información contenida en estos datos

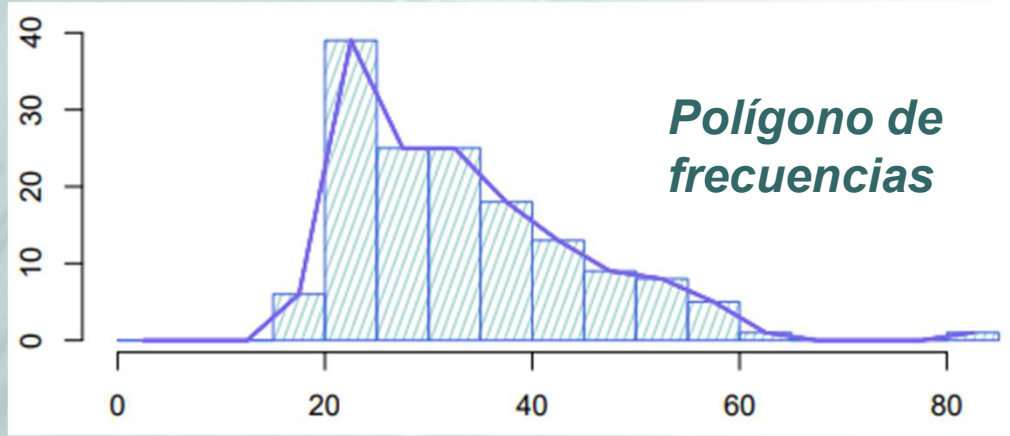
# Organización y presentación de los datos

- Variable numerica continua

| Intervalo de clase | $f_i$ (frec. absoluta) |
|---|---|
| $[0, 2)$ | 7 |
| $[2, 4)$ | 5 |
| $[4, 6)$ | 6 |
| $[6, 8)$ | 10 |
| $[8, 10)$ | 4 |



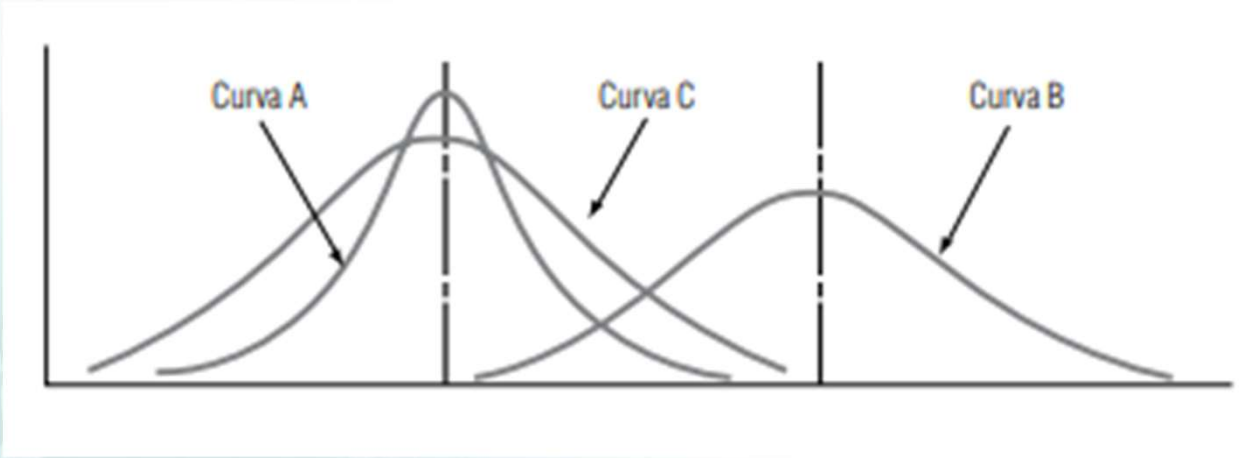

***Histograma***



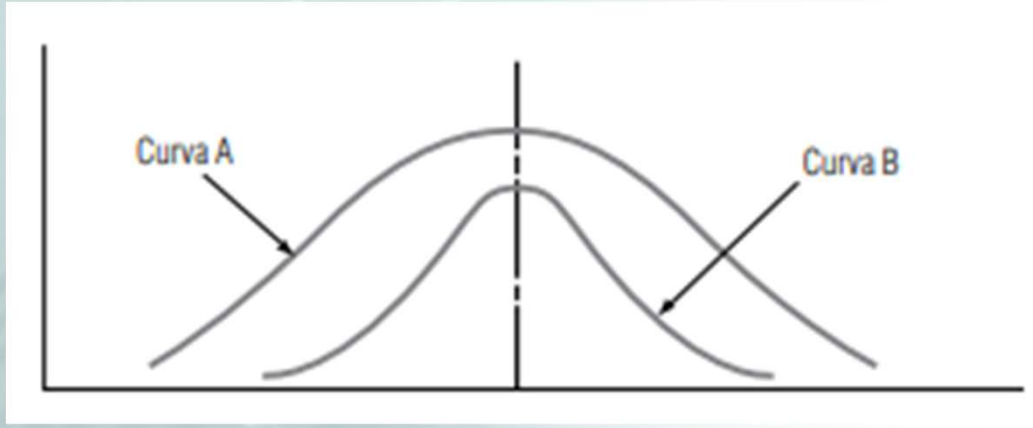

***Polígono de frecuencias***

# Medidas de posición y dispersión

**Tendencia central**

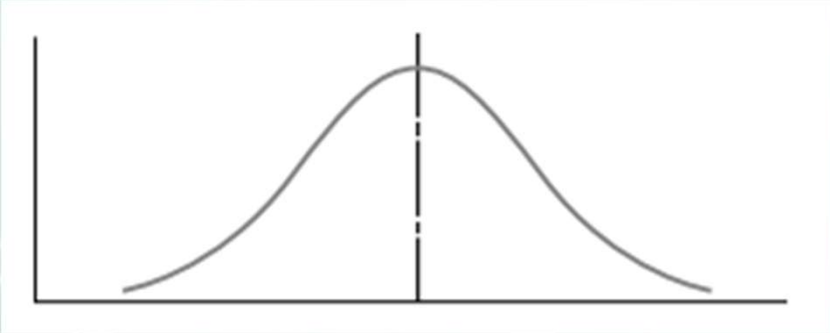



**Dispersión**

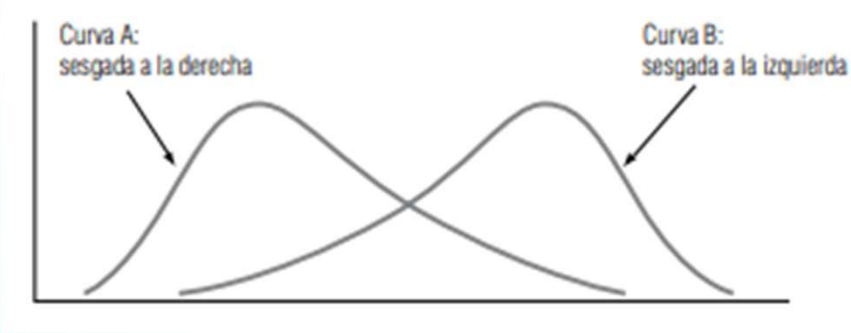


# Sesgo

- Curvas sesgadas y curvas simétricas

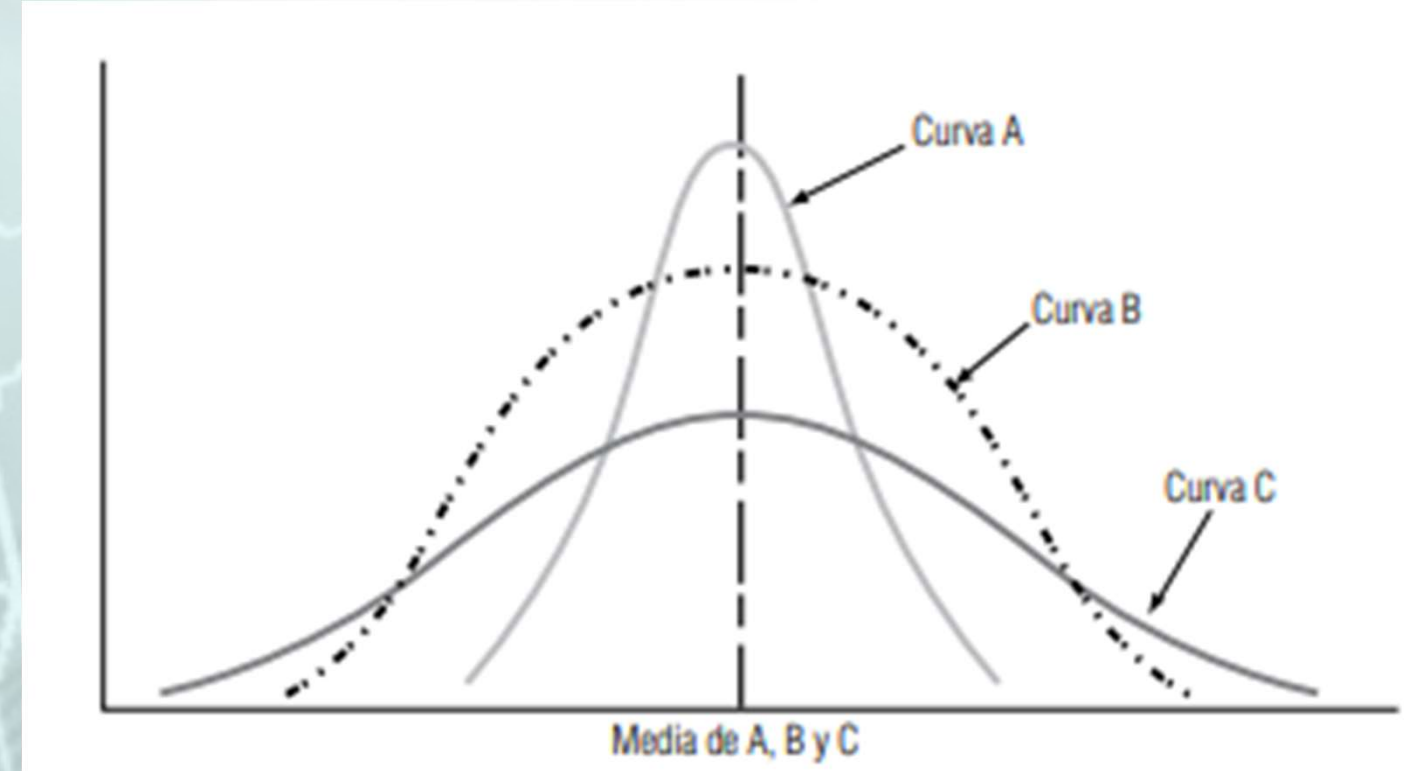


**Curva Simétrica**




**Comparación entre curvas sesgadas**

# Medidas de dispersión



# Medidas de dispersión

Las siguientes series tienen la misma amplitud, la misma media y la misma mediana

| | | |
|---|---|---|
| 1 | 1 | 1 |
| 1 | 2 | 8 |
| 2 | 5 | 8 |
| 3 | 7 | 9 |
| 3 | 9 | 10 |
| 17 | 11 | 10 |
| 17 | 13 | 11 |
| 18 | 15 | 11 |
| 18 | 17 | 12 |
| 20 | 20 | 20 |

Amplitud: 20-1=19

Media: $\bar{x} = \frac{100}{10} = 10$

Mediana: Me= 10

# Varianza

Es el promedio de los cuadrados de las distancias de las observaciones a la media

$$S^2(x) = \frac{\sum(x - \bar{x})^2 . f_i}{n - 1} \rightarrow Muestra$$

$$\sigma^2(x) = \frac{\sum(x - \mu)^2 . f_i}{N} \rightarrow Población$$

**Fundamento Teórico**

La razón para este cambio de denominador es que la varianza muestral calculada de esta forma es un estimación mas precisa de la varianza poblacional, especialmente cuando *n* es pequeño.

Al calcularse como los desvíos al cuadrado de la variable respecto a la media está elevada a una magnitud superior que la variable original, por eso al interpretarla no resulta útil.

# Desviación estandar o típica

$$\sigma = \sqrt{Var(x)} = \sqrt{\frac{(x - \bar{x})^2 . f_i}{N}} \rightarrow Población$$

$$S = \sqrt{Var(x)} = \sqrt{\frac{(x - \bar{x})^2 . f_i}{n-1}} \rightarrow \text{Muestra}$$

Es un valor que indica el grado de dispersión que posee una distribución con respecto a la media

# Coeficiente de variación

Se define como coeficiente de variación en una distribución al cociente entre su desvío estándar sobre el valor de su media.

$$CV = \frac{\sigma}{\mu}$$

$$CV = \frac{\delta}{\bar{x}}$$

Ejemplo

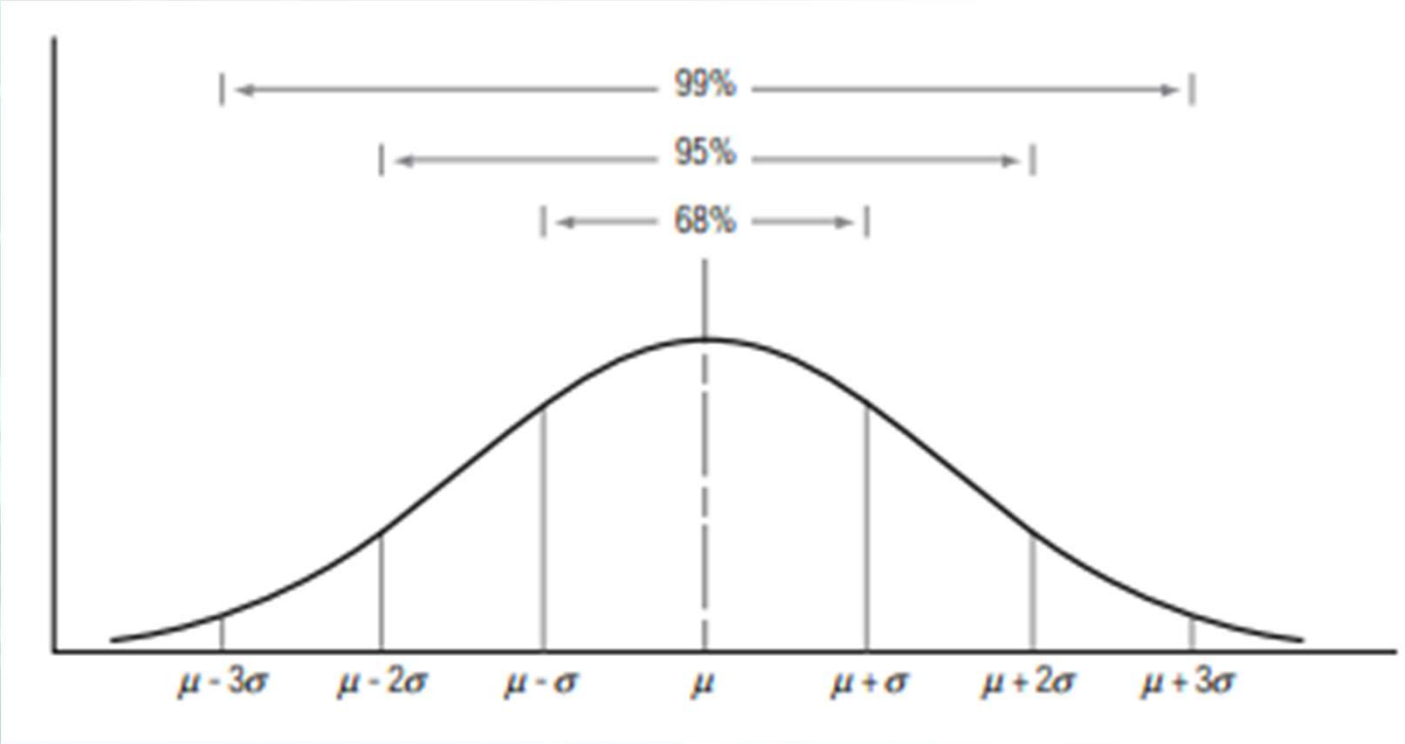
Cada día el técnico A del laboratorio realiza un promedio de 40 análisis con una desviación estándar de 5. El técnico B efectúa un promedio de 160 análisis diarios con una desviación estándar de 15. ¿Cuál de los dos técnicos muestra menos variabilidad?

$$CVA = \frac{5}{40}.100\% = 12{,}5\%$$

$$CVB = \frac{15}{160}.100\% = 9{,}4\%$$

# Usos de la desviación estándar

Teorema de Chebyshev



# Usos de la desviación estándar

Una empresa desea contratar personal para sus diversas áreas. Se presentaron 125 aspirantes resultando una edad promedio de 36 años con una desviación de 2 años. Si las edades se distribuyen en forma simétrica y la empresa decidió, que solo empleará a personas menores a 38 años, responde:

a) ¿Qué porcentaje de aspirantes estarán en condiciones de conseguir el trabajo?

b) ¿Qué cantidad de personas fueron excluidas?

# Intervalos de clases

Cuando el numero de observaciones es mayor a 20 es conveniente tomar intervalos de clases, teniendo en cuenta:

1) El numero de intervalos z debe cumplir 5< z <16, se adopta el valor aproximado de $\sqrt{z} = numero\ de\ intervalos$
2) La amplitud del intervalo es $\Delta x = \frac{x_n - x_1}{z}$
3) Todo intervalo está definido por su limite inferior y su limite superior:

$$[Li - Ls] \text{ó} (Li - Ls) \text{ó} (Li - Ls] \text{ó} [Li - Ls)$$

4) Los valores de un intervalo no deben coincidir con sus limites
5) No debe haber ningún intervalo con frecuencia 0, excepto en los intervalos extremos

El coeficiente intelectual (CI) de 100 estudiantes se distribuye según la siguiente tabla:

| Intervalo | Frecuencia | Marca de clase $x_m$ | Frecuencia relativa | Frecuencia acumulada | Frecuencia desacumulada |
|---|---|---|---|---|---|
| [100-110) | 12 | 110 | 0,12 | 12 | 100-12=88 |
| [110-120) | 34 | 115 | 0,34 | 46 | 100-46=54 |
| [120-130) | 38 | 125 | 0,38 | 84 | 16 |
| [130-140) | 13 | 135 | 0,13 | 97 | 3 |
| [140-150) | 3 | 145 | 0,03 | 100 | 0 |

$$x_m = \frac{ls + Li}{2}$$

# Medidas de posición

Media: $\bar{x} = \frac{\sum x_m \cdot f_i}{n}$

Mediana: $Me = \left(\frac{\frac{n}{2} - f_a}{f_m}\right).\Delta x + Li$

*Clase medial es la clase que contiene al elemento n/2*
*n = Numero total de elementos de la distribución*
*fa = Es la frecuencia acumulada de la clase anterior a la clase mediana*
*fm= frecuencia de la clase medial*
*Δx= amplitud de intervalo*
*Li: Limite inferior de la clase medial*

Moda: $Mo = Li + \Delta x.\frac{d_1}{d_1 + d_2}$

d1= la diferencia entre la frecuencia del intervalo modal y la frecuencia del intervalo que le antecede
d2= la diferencia entre la frecuencia del intervalo modal y la frecuencia del intervalo que le sucede

| Intervalo | Frecuencia | Marca de clase $x_m$ | Frecuencia relativa | Frecuencia acumulada | Frecuencia desacumulada |
|---|---|---|---|---|---|
| [100-110) | 12 | 110 | 0,12 | 12 | 100-12=88 |
| [110-120) | 34 | 115 | 0,34 | 46 *fa* | 100-46=54 |
| [120-130) | 38 *fm* | 125 | 0,38 | 84 | 16 |
| [130-140) | 13 | 135 | 0,13 | 97 | 3 |
| [140-150) | 3 | 145 | 0,03 | 100 | 0 |

$\bar{x} = 121{,}7$

Me=$\frac{50-46}{38}$. 10 + 120

Me=121,05

Mo=120 + 10. $\frac{4}{4+25}$

Mo=121,38

# Medidas de dispersión

Varianza

$$Var(x) = \frac{\sum(x_m - \mu)^2 . f_i}{N} \rightarrow Población$$

$$Var(x) = \frac{\sum(x_m - \bar{x})^2 . f_i}{n - 1} \rightarrow Muestra$$